

UNIVERSITÉ DE LILLE



MASTER 2 MIASHS

Projet pour l'entreprise

Auteur:

LUCCIN PEMBELE

Contents

1	Introduction	2
1.1	Contexte	2
1.2	Problématique et méthodologie	2
1.3	Détails de la base de données	2
1.4	Nettoyage et préparation des données	3
2	Analyse descriptive et spatiale	4
2.1	Analyse descriptive	4
2.2	Analyse spatiale	9
2.3	Analyse de la fréquentation et de la ponctualité	9
2.3.1	Le système français : Paris, centre névralgique	9
2.3.2	Analyse par zones géographiques	11
2.3.3	Le coté international	12
2.3.4	Synthèse de l'état des lieux	12
3	Analyse structurelle	13
3.1	Analyse en composantes principales	13
3.1.1	Valeurs propres	13
3.1.2	Interprétation graphique des variables	13
3.1.3	Interprétation graphique des individus	16
3.2	Clustering	19
3.2.1	Choix du nombre de classe et répartition	19
3.2.2	Identification des groupes	20
3.2.3	Analyse des groupes	22
4	Analyse prédictive	24
4.1	Prévision de l'évolution des retards	24
5	Recommandation et Conclusion	26
6	Annexes	27
6.1	Listes des trajets par groupe	27

1 Introduction

1.1 Contexte

La régularité du transport ferroviaire constitue un enjeu stratégique majeur pour les entreprises de transport public, et en particulier pour la SNCF. Aujourd'hui, la SNCF évolue dans un environnement de plus en plus concurrentiel, marqué par le développement d'alternatives telles que le transport aérien à bas coût, le covoiturage ou encore l'usage accru de la voiture. Dans ce contexte, la ponctualité des trains devient un facteur déterminant, influençant directement la satisfaction des voyageurs, les coûts que cela peut engendrer ainsi que l'image de l'entreprise.

Afin de faire face à ces enjeux, analyser et comprendre les mécanismes à l'origine des retards représente une étape importante dans l'amélioration de la qualité de service. L'objectif est également d'identifier les causes et d'anticiper les situations à risque afin de proposer des solutions de correction.

1.2 Problématique et méthodologie

La problématique centrale de ce projet est donc la suivante:

Comment identifier, expliquer et prévoir les retards des lignes TGV afin d'améliorer la régularité et la satisfaction client ?

Pour répondre à cette problématique, nous avons structuré notre démarche en 3 étapes combinant:

- **Une analyse descriptive et spatiale** : pour comprendre les tendances historiques, identifier les lignes et périodes critiques, et visualiser les données. ;
- **Une analyse structurelle** pour segmenter le réseau en profils homogènes, en utilisant des méthodes avancées comme l'ACP et le clustering. ;
- **Une analyse prédictive** en utilisant les séries temporelles pour simuler l'évolution du retard et proposer des mesures proactives. ;

1.3 Détails de la base de données

Ce travail s'appuie sur une base de données mise à disposition par la SNCF: <https://www.data.gouv.fr/datasets/regularite-mensuelle-tgv-par-liaisons>. Au total, ce jeu de données comporte 10 687 observations. Elle regroupe, pour chaque ligne (trajet), des informations mensuelles détaillées sur la ponctualité des trains ainsi que sur la répartition des retards selon leurs différentes causes. Elle couvre la période allant de janvier 2018 à mars 2025.

Table 1: Variables de la base de données

Variables	Significations	Type
Date	Mois et année du relevé	Date
Service	Type de liaison (International ou National)	Catégorie
Gare.de.départ	Nom de la gare de départ	Texte
Gare.d.arrivée	Nom de la gare d'arrivée	Texte
Durée.moyenne.du.trajet	Temps de trajet moyen constaté	Minutes
Nombre.de.circulations.prévues	Nombre de circulations prévues	Nombre
Nombre.de.trains.annulés	Trains supprimés	Nombre
Commentaire.annulations	Motif des annulations	Texte
Nombre.de.trains.en.retard.au.départ	Nombre de trains en retard au départ	Nombre
Retard.moyen.des.trains.en.retard.au.départ	Retard moyen au départ (uniquement trains retardés)	Minutes
Retard.moyen.de.tous.les.trains.au.départ	Retard moyen global au départ	Minutes
Commentaire.retards.au.départ	Commentaires liés aux causes des retards au départ	Texte
Nombre.de.trains.en.retard.à.l.arrivée	Nombre de trains en retard à l'arrivée	Nombre
Retard.moyen.des.trains.en.retard.à.l.arrivée	Retard moyen à l'arrivée (uniquement trains retardés)	Minutes
Retard.moyen.de.tous.les.trains.à.l.arrivée	Retard moyen global à l'arrivée	Minutes
Commentaire.retards.à.l.arrivée	Explications des retards à l'arrivée	Texte
Nombre.trains.en.retard...15min	Trains ayant plus de 15 min de retard	Nombre
Retard.moyen.trains...15.si.liaison...	Retard moyen (>15min) sur liaisons aériennes	Minutes
Nombre.trains.en.retard...30min	Trains ayant plus de 30 min de retard	Nombre
Nombre.trains.en.retard...60min	Trains ayant plus de 60 min de retard	Nombre
Prct.retard.pour.causes.externes	Part des retards dus à des causes externes	Pourcentage
Prct.retard.pour.cause.infrastructure	Part des retards dus aux infrastructures	Pourcentage
Prct.retard.pour.cause.matériel.roulant	Part des retards dus au matériel train	Pourcentage
Prct.retard.pour.cause.gestion.trafic	Part des retards dus à la circulation	Pourcentage
Prct.retard.pour.cause.gestion.en.gare...	Part des retards dus à la gestion en gare	Pourcentage
Prct.retard.pour.cause.prise.en.compte...	Part des retards dus aux voyageurs	Pourcentage

L'information se décompose en 4 dimensions:

- **Identification spatio-temporelle** : gare de départ, gare d'arrivée, service ;
- **La quantité des trains** : Nombre de circulations prévues, Nombre de trains supprimés ;
- **La régularité** : Retard moyen au départ, Retard moyen à l'arrivée, Trains ayant plus de 15, 30 et 60 min de retard ;
- **Les causes** : Part des retards dus aux infrastructures, causes externes, matériel, gestion en gare, voyageurs, circulations.

1.4 Nettoyage et préparation des données

Bien que cette base de données soit complète et riche en informations, son exploitation optimale nécessite un nettoyage préalable. Cette étape est essentielle pour corriger d'éventuelles incohérences, valeurs manquantes ou erreurs de saisie, et ainsi garantir la fiabilité des analyses ultérieures

Les opérations suivantes ont été réalisées :

- **Renommage et simplification** : Les intitulés des variables d'origine étant longs et complexes (ex: "*Retard.moyen.des.trains.en.retard.au.départ*"), nous les avons simplifié pour faciliter leur manipulation (ex: "*retard_moyen_train_depart*").

- **Traitement des valeurs manquantes** : L'analyse exploratoire a révélé que les colonnes de commentaires (*commentaire_annulations*, etc.) étaient entièrement vides (10 687 valeurs manquantes sur 10 687 observations). Elles ont donc été supprimées pour alléger la base.
- **Gestion temporelle** : La variable *Date*, initialement au format texte, a été convertie au format Date. Deux nouvelles variables, *Mois* et *Année*, ont été extraites pour permettre l'analyse de la saisonnalité.
- **Filtrage des incohérences** : Nous avons identifié et supprimé les lignes indiquant un nombre de circulations prévues égal à 0, correspondant à des liaisons inactives sur la période donnée.
- **Création de variables** : Pour affiner l'analyse, nous avons construit trois indicateurs clés :
 - **Trajet** : concaténation des gares de départ et d'arrivée pour créer un identifiant unique par ligne.
 - **Nb_circulations** : calcul du trafic réel (*Circulations prévues* - *Trains annulés*).
 - **Taux_retard** : notre variable cible principale, calculée comme le rapport entre le nombre de trains en retard à l'arrivée et le nombre de circulations réelles.

2 Analyse descriptive et spatiale

Une fois les données nettoyées et préparées, nous passons à l'analyse descriptive afin de dresser un état des lieux global de la régularité du réseau TGV. Cette première étape permet d'identifier les grandes tendances, de mettre en évidence les lignes les plus problématiques et de comprendre la structure générale des retards avant d'introduire des méthodes plus avancées.

2.1 Analyse descriptive

Nombre de lignes	Moyenne du nombre de retard au départ	Nombre moyen de minutes de retard au départ
130	87.34	12.03

Table 2: Statistiques clés

Nombre de retard à l'arrivée	Nombre de minutes de retard à l'arrivée	taux de retard	Nombre de circulation
6.88	34.90	0.14	261.84

Table 3: Statistiques clés (moyenne)²

Les deux tableaux ci-dessus présentent les principales statistiques descriptives obtenues à partir de la base de données par trajet.

La base de données comportant 130 lignes (trajets) distincts (en incluant les trajets aller-retour), avec un nombre moyen de 87 trains en retard au départ par ligne et un retard moyen au départ de 12,03 minutes. À l'arrivée, le nombre moyen de trains en retard s'élève à 6,88, avec un retard moyen de 34,9 minutes, ce qui signifie que les retards, même si ils sont moins fréquents à l'arrivée que au départ, peuvent être significativement plus longs.

Le taux de retard moyen, défini comme la proportion de trains arrivant en retard parmi les circulations, est de 0,14 soit 14% pour un nombre de circulations de 262 par mois et par ligne. Un taux de retard de 14% a un impact direct sur la satisfaction des voyageurs et la réputation de la SNCF. Les retards prolongés à l'arrivée peuvent également perturber les correspondances et les plans des voyageurs.




Figure 1: Distribution du taux de retard mensuels

En visualisant l'histogramme représentant la distribution du taux de retard mensuel, on observe que la majorité des observations se concentrent entre 0,05 et 0,25. La distribution présente un pic autour des valeurs 0,14–0,15, indiquant qu'un nombre important d'observations mensuelles correspondent à des taux de retard compris entre 14 % et 15 %. Autrement dit, pour une grande partie des couples trajet-mois, environ un train sur sept arrive en retard à destination.

Cette analyse est complétée par l'étude des boxplots du taux de retard par mois, qui permettent de mettre en évidence la variabilité saisonnière de la régularité.





Figure 2: Répartition du pourcentage moyenne des causes de retard

Les boxplots montrent que le mois de Juin (6), Juillet (7) ainsi que faiblement le mois de Novembre (11) ont des médianes un peu plus élevées. Le mois de Juin et Juillet présentent également une dispersion plus importante, traduisant des périodes où le réseau est plus exposé aux retards. Cette variabilité peut être expliquée par plusieurs facteurs. En période estivale, l'augmentation de l'affluence des voyageurs, liée aux vacances, entraîne une pression accrue sur le réseau ferroviaire. À cela s'ajoutent des opérations de maintenance et de travaux sur les infrastructures, souvent programmées durant l'été, ainsi que des conditions météorologiques défavorables, telles que la canicule.

Les boxplots ont mis en évidence une variabilité saisonnière des retards, notamment pendant les mois d'été. Pour approfondir cette analyse, examinons maintenant les trajets qui présentent les taux de retard les plus élevés.



(a) Top 10

(b) Flop 10

Figure 3: Les 10 trajets avec le taux de retard les plus et moins élevé

Ces deux graphiques présentent respectivement les dix trajets affichant les taux de retard mensuels les plus élevés et les plus faibles. Parmi les dix trajets présentant les taux de retard mensuels les plus élevés, le trajet Italie – Paris Lyon se distingue particulièrement, avec un taux de retard moyen d'environ 0,31, ce qui signifie que près de 31 % des trains arrivent en retard à destination. Par ailleurs, on constate que la majorité des trajets affichant les taux de retard les plus élevés correspondent à des lignes arrivant en Île-de-France, telles que Chambéry – Paris Lyon, Mâcon – Paris, Arras – Paris, Douai – Paris, Le Mans – Paris Montparnasse ou encore Lyon – Marne-la-Vallée. Le fait que de nombreux trajets fortement retardés arrivent en Île-de-France montre que cette zone constitue un point sensible du réseau, où la densité de circulation rend la gestion des retards plus difficile.

À l'inverse, certains trajets se distinguent par des taux de retard très faible c'est notamment le cas du trajet Marseille St Charles - Madrid avec un taux de 0.074. Certains trajets peuvent bénéficier d'une densité de trafic moins élevée, ce qui réduit les risques de retards, ça peut être le cas du trajet Paris Lyon - Dijon (0.088).




Figure 4: Les 10 trajets avec le nombre de retard les plus et moins élevé

Ces graphiques présentent les dix trajets affichant le nombre de trains en retard mensuels les plus élevés et les plus faibles. Parmi les dix trajets affichant le nombre de trains en retard mensuels les plus faibles, on retrouve le même trajet aller-retour, Nantes – Paris Vaugirard, Strasbourg – Nantes, Bordeaux – Tourcoing et Marseille St Charles – Madrid. Cette double présence montre une stabilité de l'exploitation sur ces axes. À l'inverse, les trajets les plus en retard sont souvent ceux qui arrivent ou partent de grandes gares comme Paris Montparnasse, où la densité de trafic et la complexité des opérations augmentent les risques de retards.

Nous allons maintenant analyser la répartition des causes des retards. Cette étape permettra de mettre en lumière les facteurs principaux contribuant aux retards sur le réseau ferroviaire.




Figure 5: Répartition du pourcentage moyenne des causes de retard

	cause	pourcentage
1	Externe	21.87
2	infra	22.10
3	trafic	20.14
4	materiel	19.09
5	gestion	7.30
6	voyageurs	7.68

Table 4: Répartition moyenne des causes de retard

Le graphique met en évidence les différentes causes contribuant aux retards des trains. On observe que les causes liées à l'infrastructure (22,10 %) et aux facteurs externes (21,87 %) constituent les principales sources de retard. Les causes infrastructurelles regroupent notamment les maintenances et les travaux sur les rails tandis que les causes externes regroupent la météo, obstacles, colis suspects, malveillance, mouvements sociaux, etc... Les retards liés à la gestion du trafic (20,14 %) et au matériel roulant (19,09 %) recouvrant les problèmes liée au train (pannes...), occupent également une part importante. La cause de gestion trafic regroupent la circulation sur les lignes ferroviaire ainsi que les interactions réseaux. À l'inverse, les causes à la gestion en gare et réutilisation de matériel (7,30 %) et aux voyageurs (7,68 %) incluant affluence, correspondances apparaissent nettement plus faibles que les autres causes.

2.2 Analyse spatiale

2.3 Analyse de la fréquentation et de la ponctualité

Dans cette partie, nous analysons la relation entre la densité du trafic et la ponctualité des trains. En croisant le nombre de départs (taille des cercles), le taux de retard (pour cette partie, nous utilisons les taux de retard des départs afin de visualiser la différence entre les retards à l'arrivée et au départ. Le reste du projet sera axé sur le taux de retards à l'arrivée.) (couleur) et la durée moyenne des délais (survol: **À voir sur la carte interactive**), nous identifions précisément les points de saturation du réseau.




Figure 6: Répartition du pourcentage moyenne des causes de retard

2.3.1 Le système français : Paris, centre névralgique

Cette analyse confirme que le réseau français est radial : tout s'organise autour de Paris, qui agit comme le cœur du système.

	depart	circulation	taux
1	PARIS LYON	525244	18.62
2	PARIS MONTPARNASSE	498527	25.33
3	LYON PART DIEU	169993	62.35
4	PARIS EST	131438	29.28
5	MARSEILLE ST CHARLES	120096	26.38
6	PARIS NORD	112327	25.58
7	LILLE	93972	36.79
8	BORDEAUX ST JEAN	78935	30.63
9	RENNES	67288	38.47
10	MARNE LA VALLEE	52409	65.71

Table 5: Top 10 du nombre de circulation




Figure 7: Top 10 du nombre de circulation

- **Paris** : Avec environ 1 270 000 trajets prévus (soit près de la moitié des 2 877 884 trajets de la base totale), Paris est le cœur du système. Cependant, le volume ne dicte pas la performance : si Paris-Lyon gère plus de 525 000 trains avec une régularité exemplaire (moins de 18 % de retards), la périphérie souffre. Marne-la-Vallée, gare d'interconnexion majeure, culmine à 65 % de retard, payant sa position de nœud où convergent les retards accumulés sur les lignes de province à province.
- **Les Hubs Régionaux (Lyon, Marseille, Lille, Bordeaux)** : Derrière le centre névralgique parisien, le réseau s'articule autour de grandes métropoles régionales. L'analyse des cinq gares les plus fréquentées montre que le volume de trafic ne conditionne pas systématiquement le taux d'échec :

Lyon (169993 départs) : C'est le point le plus critique des grandes métropoles avec un taux de retard frôlant les 60 %.

Marseille (120096 départs) : Un volume massif qui maintient une performance intermédiaire sur la façade méditerranéenne.

Lille (93972 départs) : Un hub stratégique vers le Nord et l'Europe.

Bordeaux (78935 départs) : La porte d'entrée du Sud-Ouest.

Dans ce top 5, les pourcentages de retard varient du simple au triple, prouvant que la gestion locale et l'infrastructure propre à chaque région priment sur le simple nombre de trains.

2.3.2 Analyse par zones géographiques

- **La région Lyonnaise :**

On remarque que toutes les gares proches de Lyon, de Dijon à Valence, subissent des retards très fréquents (plus de 50 % des trains). Cependant, ces retards restent relativement courts, oscillant entre 4 et 15 minutes. Seules les gares de Saint-Étienne (21 % de retard) et Grenoble (10 %) se démarquent par leur fiabilité en fréquence. En revanche, lorsqu'un incident y survient, la gravité est bien plus forte : 17 minutes de retard moyen pour Saint-Étienne et un record de 32 minutes pour Grenoble.

- **La zone Nord**

Au Nord, la situation est très hétérogène. Le taux de retard oscille entre 49 % pour Arras et moins de 5 % pour Dunkerque. Si Arras est souvent impactée, elle bénéficie du temps de retard moyen le plus faible de la zone (moins de 8 minutes). À l'inverse, Tourcoing affiche un taux de retard faible (17 %) mais des délais plus longs lorsqu'ils surviennent (17 minutes).

- **La façade Méditerranéenne et l'Ouest :**

Méditerranée : Les retards y sont structurels, compris entre 25 % et 51 %, pour des durées moyennes stables entre 9 et 12 minutes.

L'extrême Ouest : Les gares de Brest et Quimper présentent des profils similaires. Malgré leur éloignement, elles possèdent des taux de retard presque identiques (15 % et 16 %) et des temps de retard significatifs allant de 17 à 20 minutes, illustrant les difficultés des fins de lignes.

- **La Région Parisienne et l'interconnexion :**

En Île-de-France, les gares intra-muros maintiennent une certaine régularité (17 % à 26 % pour 12 à 15 minutes de retard). Seule Marne-la-Vallée se distingue radicalement du reste de la région avec 65 % de retards (pour 10 minutes de moyenne), confirmant son rôle complexe de gare de transit pour les liaisons de province à province.

2.3.3 Le coté international

L'analyse des gares étrangères connectées au réseau français révèle une performance globale en deçà des standards domestiques, soulignant les défis de l'interopérabilité européenne.

- **L'axe Espagnol** : On observe une dualité entre les deux principales métropoles. Barcelone domine largement en volume avec près de 38 000 départs vers la France, mais affiche un taux de retard préoccupant de 36 %. À l'inverse, Madrid présente un volume beaucoup plus confidentiel (929 trajets). Cet écart s'explique par la fonction de Madrid comme capitale centrale : l'essentiel de son trafic est dirigé vers l'intérieur de l'Espagne, tandis que Barcelone agit comme un hub transfrontalier naturel. Les deux villes partagent cependant une durée de retard moyenne similaire, autour de 5 minutes.
- **L'axe Italien** : La situation de la gare italienne est la plus critique de notre échantillon. Avec un taux de retard dépassant les 80 % et un temps de retard moyen de 12 minutes, elle constitue le point de congestion le plus sévère, impactant quasi-systématiquement la ponctualité des flux entrants sur le territoire français.
- **L'axe Allemand** : Les performances y sont très hétérogènes. Si Francfort affiche un taux de retard de 59 %, la situation est bien plus dégradée à Stuttgart, où 78 % des trains partent en retard avec une moyenne de 5 à 8 minutes. Ces chiffres témoignent des difficultés de gestion de trafic sur les lignes à grande vitesse rhénanes.
- **L'excellence relative de la Suisse** : Les gares helvétiques se distinguent par une gestion de la précision remarquable. Bien que les taux de retard soient élevés (entre 62 % pour Zurich et plus de 71 % pour Genève), les durées de ces retards sont les plus faibles du réseau, oscillant entre 2 et 4,5 minutes. Cela suggère un réseau extrêmement cadencé où la moindre seconde est comptabilisée, mais où le rattrapage est très efficace.

2.3.4 Synthèse de l'état des lieux

Cette cartographie met en lumière deux types de vulnérabilités :

- **Les zones de congestion (ex: Lyon, Marne-la-Vallée)** : Retards fréquents mais courts, liés à la densité du trafic.
- **Les zones de fragilité structurelle (ex: Grenoble, Brest)** : Retards rares mais longs, liés à des incidents d'infrastructure ou des difficultés de rattrapage sur le trajet.

3 Analyse structurelle

3.1 Analyse en composantes principales

L'analyse descriptive et spatiale a permis de quantifier les retards et aussi d'identifier les principales causes associées à l'irrégularité du trafic ferroviaire. Toutefois, cette approche sur les causes de retard reste univariée, elle considère chaque cause de retard indépendamment des autres. Cependant, dans la réalité, un incident d'infrastructure peut entraîner des perturbations de trafic puis peuvent affecter provoquer des retards liés aux voyageurs. L'étude des seules moyennes par cause ne permet donc pas de saisir la relation entre plusieurs causes à l'origine d'un retard. Pour répondre à ce problème et comprendre les interactions entre les différentes causes de retards, on utilise l'Analyse en Composantes Principales (ACP). Elle permet de réduire les 6 variables de causes à quelques dimensions, d'identifier les corrélations entre les causes et d'identifier des profils types. Afin d'effectuer cette analyse, nous avons effectué un tableau croisé où nous obtenons le pourcentage moyen des chaque causes pour chacun des 130 trajets.

3.1.1 Valeurs propres


	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	1.95	32.43	32.43
comp 2	1.64	27.36	59.79
comp 3	1.11	18.58	78.37
comp 4	0.71	11.80	90.17
comp 5	0.41	6.82	96.99
comp 6	0.18	3.01	100.00

Le tableau des valeurs propres permet de déterminer le nombre de dimensions nécessaires pour résumer l'information sans perte excessive. Il détaille le pourcentage de variance pour chaque axe. Le premier axe explique 32,43% c'est-à-dire que 32,43% des informations sont expliquées sur cet axe. Le deuxième axe explique 27,36% des informations, on a un cumul des deux axes de 59,79 % . En statistique, un seuil supérieur à 70-75% est considéré comme excellent, c'est pour cela qu'il faut regarder l'axe 3. Cet axe explique 16.58 % des informations soit un cumul de 78.37%. Ce résultat permet de réduire l'espace d'analyse de 6 variables à 3 dimensions.


3.1.2 Interprétation graphique des variables

	Dim.1	Dim.2	Dim.3
Externe	24.31	14.33	1.78
infra	12.45	16.35	0.07
trafic	0.86	53.00	1.31
matériel	20.09	10.01	31.90
gestion	35.19	0.97	4.97
voyageurs	7.10	5.35	59.98


Table 6: Contribution des variables sur les axes



(a) Axe 1-2



(b) Axes 1-3



(c) Axes 2-3

Figure 8

L'analyse du tableau des contributions des variables sur les axes et les cercles de corrélations montrent que: Sur l'axe 1, les causes de retard liée à la gestion en gare et réutilisation de matériel contribuent positivement (35,19%) ainsi que les causes dû au matériel roulant (20,09%). Ces variables s'opposent avec les causes externes (24,31%). Cet axe semble opposer les causes internes (gestion et entretien matériel)

aux causes externes.

L'axe 2 est dominé par la gestion du trafic avec un pourcentage de 53% suivi de loin avec les causes externes (16,35%) et infrastructure ferroviaires (14,33%). Sur cet axe, les causes liées à l'infrastructure et les causes externes sont portées positivement sur l'axe 2 tandis que les causes de retard liées à la gestion du trafic sont portées négativement sur l'axe 2. Une ligne se situant dans le côté négatif de l'axe est une ligne dont la régularité est empêchée par la densité de circulation. À l'inverse, une ligne se situant du côté positif souffre de fragilités liées à l'état des voies ou à la météo, même si le trafic est moins dense.

Le troisième axe est caractérisé par une très forte contribution des causes liées aux voyageurs (59,98 %) (positivement) et des causes liées au matériel roulant (31,90 %) (négativement). Cet axe oppose les flux de voyageurs, correspondances aux causes techniques (pannes de rames). Ce sont des trajets où le matériel est fiable, mais où la densité de voyageurs est un facteur de retard.

En ce qui concerne les corrélations entre les variables, Les variables "Infrastructure ferroviaire" et "Causes Externes" sont corrélées positivement. Cette forte corrélation indique que ces deux causes surviennent souvent simultanément: les intempéries ou obstacles impactent les installations ferroviaires (infrastructure). Les variables "Gestion en gare et réutilisation du matériel" et "Prise en compte des voyageurs" sont aussi fortement corrélées positivement. Cela confirme que les retards liés à l'affluence des passagers et ceux liés à l'organisation en gare (correspondances, préparation) surviennent souvent simultanément.

Sur le plan 1-3, les variables "Voyageurs" et "Matériel Roulant" sont corrélés négativement. Cette corrélation indique que les pannes techniques et l'affluence des voyageurs sont deux phénomènes différents.

3.1.3 Interprétation graphique des individus




Figure 9: Axe 1-2




Figure 10: Axe 1-3




Figure 11: Axe 2-3

Après avoir défini les axes, la projection des trajets sur les différents plans permet d'identifier les lignes qui se situent dans chaque type de cause.

Sur le premier plan factoriel opposant les causes internes (gestion en gare et matériel) aux causes externes, la partie droite du graphique regroupe les trajets dont les retards sont dû aux causes externes, on y retrouve des trajets comme Paris Est - Strasbourg, Paris Lyon - Dijon Ville ou Paris Lyon - Valence. Ces lignes sont très sensibles à la qualité de la gestion en gare (préparation des rames, logistique à quai) et à la disponibilité immédiate du matériel.

À l'opposé, les lignes telles que Quimper - Paris Montparnasse et Toulouse Matabiau - Paris Montparnasse, Perpignan - Paris Lyon . Leurs retards sont majoritairement causés par l'état des infrastructures ou des causes externes (météo, malveillance).

Pour le deuxième axe opposant la gestion du trafic et les causes externes et infrastructures ferroviaires, Les lignes internationales (Madrid - Marseille, Barcelone - Paris, Stuttgart - Paris-Est, Italie - Paris, Paris Est-Francfort), plongent vers le pôle "Trafic". À l'opposé, les lignes de la partie Atlantique (Brest, Quimper, la Rochelle, Vannes), plus exposées aux intempéries et infrastructures, remontent vers le pôle "Infrastructure/Externe".

Et enfin pour le troisième axe opposant la prise en compte des voyageurs et le matériel roulant, Les lignes longues comme Marseille St Charles - Tourcoing et Nantes-Strasbourg ainsi que la ligne Lyon Part Dieu - Paris Lyon très fréquentée, se projettent vers le haut. Elles subissent les contraintes d'une exploitation dense avec beaucoup de voyageurs et de correspondances.

À l'opposé, la liaison Bordeaux St Jean - Paris Vaugirard plonge vers le bas du graphique, signalant une vulnérabilité spécifique liée au problème de train sur cet axe.

En résumé, l'ACP met en évidence 3 dimensions:

- **Causes interne vs externe et infrastructure**
- **Trafic vs infrastructure et externe**
- **Voyageur vs Matériel roulant (train)**

3.2 Clustering

Au départ, on avait un gros tableau avec 6 causes de retard différentes, ce qui était assez complexe à manipuler. L'ACP nous a permis de simplifier tout ça en gardant que 3 grandes dimensions, ce qui nous a aidés à comprendre les causes générales des retards sur tout le réseau.

Mais on avait besoin de savoir concrètement quelles lignes sont touchées par quel problème. C'est là que le clustering entre en jeu : c'est l'étape qui vient vraiment concrétiser l'ACP.

Le clustering utilise les dimensions qu'on a trouvées juste avant pour découper nos 130 lignes en plusieurs groupes (cluster).

3.2.1 Choix du nombre de classe et répartition

Pour déterminer le nombre optimal de groupes, deux critères sont à disposition:

- **La méthode du coude** Elle consiste à observer la décroissance de l'inertie intra-classe en fonction du nombre de clusters. On cherche le point de rupture (le "coude") à partir duquel l'ajout d'un cluster supplémentaire ne permet pas d'améliorer considérablement la variance expliquée.
- **Méthode de la silhouette** Elle mesure la cohésion et la séparation des clusters. Le coefficient varie de -1 à 1 où une valeur proche de 1 indique une bonne séparation des clusters.




Figure 12: Détermination du nombre de classe

Sur le graphique de la méthode du coude, on observe une forte diminution de l'inertie lorsque le nombre de clusters passe de 1 à 4. Au-delà de 4 clusters, la décroissance devient nettement plus progressive, indiquant que l'ajout d'un groupe supplémentaire ne permet pas d'améliorer considérablement la variance expliquée. Ce changement de pente suggère un point de rupture autour de 4 clusters. Le graphique (b) montre que la valeur maximale de l'indice de silhouette est atteinte pour $k = 2$ clusters, avec une valeur proche de 0,25. Toutefois, des valeurs comparables sont observées pour $k = 4$. Donc en combinant les deux critères, le choix de 4 clusters apparaît comme le plus pertinent.

3.2.2 Identification des groupes

	Fréquence
1	25
2	19
3	44
4	42

Table 7: Répartition des lignes par classe

La répartition des lignes par classe montre un grand nombre d'observation dans le groupe 3 et 4 avec 44 et 42 observations. Les groupes 1 et 2 sont moins volumineux avec 25 et 19 observations.




Figure 13: Distribution des causes sur les 4 clusters identifié

	cluster	Externe	infra	trafic	materiel	gestion	voyageurs
1	1	26.77	26.51	17.16	16.15	5.36	7.35
2	2	19.61	21.05	15.75	28.25	7.43	4.56
3	3	19.61	18.73	33.03	12.70	4.50	3.87
4	4	19.41	19.61	20.72	19.48	9.50	10.27

L'analyse des classes et la distribution visuelle des causes nous permettent de définir l'identité de chaque cluster.

Le premier cluster se caractérise par une très forte prédominance des causes externes (26.77%) et infrastructures (26.51%).

Le deuxième cluster est défini par la variable "Matériel roulant" qui atteint ici 28.25%. Dans ce groupe, les retards sont liés par des pannes de trains ou des dysfonctionnements du matériel roulant.

Le troisième cluster est dominé par la variable "Trafic" avec 33.03%. Les retards dans ce cluster sont principalement dus à des problèmes de gestion de trafics.

Et enfin, le cluster 4 est représenté par la gestion en gare et réutilisation du matériel (9.50%) et voyageurs (10.27%).




Figure 14: Projection des clusters sur les axes de l'ACP

Ces deux graphiques confirment la pertinence de notre segmentation :

- **Le Cluster 1 (Rouge)** représente les **causes externes et infrastructures** : il se projette vers « Externe » et « Infra » sur l'axe 1 et 2.
- **Le Cluster 2 (Vert)** est défini par **matériel roulant** : il s'isole dans la partie inférieure du plan, suivant « Matériel ».
- **Le Cluster 3 (Bleu)** est défini par le **trafic** : il se situe à gauche du plan 2-3, pile dans l'axe de la variable « Trafic ».
- **Le Cluster 4 (Violet)** symbolise la **gestion et les voyageurs** : il occupe la partie supérieure du graphique, là où les variables « Voyageurs » et « Gestion » sont les plus fortes.

3.2.3 Analyse des groupes

La liste complète des trajets par cluster est présentée en annexe (Annexe 7.1)

Le Groupe 1 regroupe majoritairement des trajets partant des côtes Est et Sud de la France et arrivant à Paris, ce qui en fait des axes stratégiques pour le réseau. Parmi ces lignes, on retrouve par exemple Aix-en-Provence TGV – Paris Lyon, Angers Saint-Laud – Paris Montparnasse ou Brest – Paris Montparnasse. Ces trajets sont particulièrement sensibles aux retards liés aux facteurs externes et aux infrastructures.

À l'inverse du premier groupe, le Groupe 2 se concentre massivement sur les trajets au départ de Paris et surtout la gare de Paris Lyon vers la province (ex : Paris Lyon – Marseille, Paris Lyon – Grenoble). Les problématiques liées au matériel roulant surviennent principalement lors de la mise à quai dans les grandes gares parisiennes.

Le Groupe 3, caractérisé par des retards liés au trafic, inclut de nombreuses liaisons internationales (Francfort – Paris, Stuttgart – Paris, Italie – Paris) ainsi que des trajets régionaux comme Arras – Paris. Ces lignes sont souvent soumises à une forte densité de circulation.

Enfin, le Groupe 4 se distingue par des trajets comportant de nombreux arrêts intermédiaires (Lille – Marseille, Lyon – Montpellier, Paris – Lille, Nantes – Lyon). La structure de ces trajets explique la prédominance des retards liés à la gestion en gare et à l’affluence des voyageurs.


4 Analyse prédictive

Après avoir décrit la structure des retards et identifié les profils des retards, cette partie vise à passer d'une logique descriptive à une approche prédictive.

4.1 Prévision de l'évolution des retards

Nous adoptons ici une approche macroscopique via l'analyse des séries temporelles. L'objectif est de modéliser l'évolution du taux de retard global mois par mois, afin de détecter des tendances et d'anticiper les variations saisonnières futures.

Pour cette analyse, nous avons pris les données à l'échelle mensuelle. La variable d'intérêt est la moyenne du taux de retard pour chaque mois, de janvier 2018 à mars 2025.



(a) Taux de retard mensuel

(b) Décomposition de la série temporelle


Figure 15: Détermination du nombre de classe

La décomposition de la série temporelle du taux de retard mensuel nous montre:


Pour l'analyse de la tendance, la courbe met en évidence 3 phases: une période de régularité stable, voire une légère amélioration, oscillant autour de 16-20% en 2018-2019. Puis on observe une chute du taux de retard en 2020-2021 atteignant un minimum d'environ 10%. Cette forte baisse peut être liée la diminution du nombre de trafic durant la pandémie du COVID. Et enfin la 3 ème phase est la reprise en 2022-2025 avec le retour à un trafic normal, la tendance revient à la hausse avec un taux de retard d'environ 15%.

Pour l'analyse de la saisonnalité, la courbe est parfaitement périodique. On observe 2 pics en juin-juillet et en novembre-décembre. Ce graphique nous confirme une saisonnalité.

Cette décomposition souligne que toute modélisation prédictive doit impérativement intégrer la saisonnalité (pour anticiper les pics de juillet/décembre). Par ailleurs, la tendance actuelle montre une stabilisation post-COVID, suggérant que le taux de retard du réseau se situe désormais autour de 14%, seuil qu'il sera difficile de franchir sans investissements majeurs. Afin de prédire le futur en fonction du passé, il faut ajouter une saisonnalité.



(a) Projection du taux de retard sur les 24 prochaines mois



(b) Taux de retard entre 2018 et 2027

Figure 16: Projection du taux de retard

Ces graphiques représentant la projection du taux de retard indique que entre 2025 et 2026, le taux de retard devrait osciller entre 13 et 15% puis se stabiliser à environ 13,5%. L'analyse temporelle confirme que sans changement structurel majeur (rénovation massive, changement de processus), le taux de retard devrait osciller autour de 13-14 % dans les deux années à venir, rythmé par la saisonnalité habituelle.

5 Recommandation et Conclusion

L'analyse a révélé que les retards ne sont pas uniformes sur le réseau, mais répondent à des logiques de groupes précises :

- **Priorité à l'Infrastructure et aux causes Externes** : Ces facteurs impactent tout particulièrement le Cluster 1, qui regroupe les lignes les plus sensibles aux problèmes extérieurs et techniques des voies.
- **La gestion du Trafic** : Elle s'impose comme le défi majeur pour le Cluster 3, qui concerne les lignes saturées et internationales.
- **Les Gares/Voyageurs** : Le Cluster 4 a mis en évidence une forte corrélation entre l'affluence des passagers et les problèmes logistique à quai.

La modélisation par séries temporelles via le modèle SARIMA confirme que le réseau est soumis à une saisonnalité bivoie très marquée . Les pics critiques se situent systématiquement en juillet et en décembre. Sans intervention structurelle majeure, nos prévisions indiquent que le taux de retard moyen devrait stagner entre 13,5 % et 14 % pour les années 2026-2027.

Pour améliorer la performance du réseau :

- Moderniser prioritairement les infrastructures sur les lignes identifiées dans le Cluster 1.
- Renforcer la maintenance préventive du matériel roulant pour les lignes du Cluster 2.
- Optimiser la régulation du trafic sur les nœuds saturés pour le Cluster 3.
- Augmenter les effectifs en gare lors des pics saisonniers de juillet et décembre pour fluidifier le flux du Cluster 4.

En conclusion, la régularité de demain dépendra de la capacité à passer d'une gestion réactive à une culture de la donnée prédictive, permettant d'anticiper les crises saisonnières avant qu'elles n'impactent les voyageurs.

6 Annexes

6.1 Listes des trajets par groupe

	Groupe 2: Matériel Roulant
1	BORDEAUX ST JEAN - PARIS VAUGIRARD
2	NANTES - PARIS VAUGIRARD
3	PARIS EST - NANCY
4	PARIS EST - STRASBOURG
5	PARIS LYON - AIX EN PROVENCE TGV
6	PARIS LYON - ANNECY
7	PARIS LYON - AVIGNON TGV
8	PARIS LYON - BARCELONA
9	PARIS LYON - BELLEGARDE (AIN)
10	PARIS LYON - BESANCON FRANCHE COMTE TGV
11	PARIS LYON - CHAMBERY CHALLES LES EAUX
12	PARIS LYON - DIJON VILLE
13	PARIS LYON - GRENOBLE
14	PARIS LYON - ITALIE
15	PARIS LYON - LAUSANNE
16	PARIS LYON - LE CREUSOT MONTCEAU MONTCHANIN
17	PARIS LYON - MACON LOCHE
18	PARIS LYON - MARSEILLE ST CHARLES
19	PARIS LYON - MONTPELLIER
20	PARIS LYON - MULHOUSE VILLE
21	PARIS LYON - NIMES
22	PARIS LYON - VALENCE ALIXAN TGV
23	PARIS VAUGIRARD - BORDEAUX ST JEAN
24	PARIS VAUGIRARD - RENNES
25	TOURCOING - BORDEAUX ST JEAN

	Groupe 1: Cause externes et infrastructures
1	AIX EN PROVENCE TGV - PARIS LYON
2	ANGERS SAINT LAUD - PARIS MONTPARNASSE
3	ANGOULEME - PARIS MONTPARNASSE
4	AVIGNON TGV - PARIS LYON
5	BARCELONA - PARIS LYON
6	BELLEGARDE (AIN) - PARIS LYON
7	BESANCON FRANCHE COMTE TGV - PARIS LYON
8	BORDEAUX ST JEAN - PARIS MONTPARNASSE
9	BREST - PARIS MONTPARNASSE
10	DIJON VILLE - PARIS LYON
11	DUNKERQUE - PARIS NORD
12	GENEVE - PARIS LYON
13	LA ROCHELLE VILLE - PARIS MONTPARNASSE
14	LAUSANNE - PARIS LYON
15	LAVAL - PARIS MONTPARNASSE
16	LE MANS - PARIS MONTPARNASSE
17	LYON PART DIEU - RENNES
18	MARSEILLE ST CHARLES - PARIS LYON
19	MONTPELLIER - PARIS LYON
20	MULHOUSE VILLE - PARIS LYON
21	NANTES - PARIS MONTPARNASSE
22	NICE VILLE - PARIS LYON
23	NIMES - PARIS LYON
24	PARIS LYON - GENEVE
25	PARIS LYON - NICE VILLE
26	PARIS LYON - PERPIGNAN
27	PARIS MONTPARNASSE - BREST
28	PARIS MONTPARNASSE - NANTES
29	PARIS MONTPARNASSE - QUIMPER
30	PARIS MONTPARNASSE - ST MALO
31	PARIS MONTPARNASSE - TOULOUSE MATABIAU
32	PARIS NORD - DUNKERQUE
33	PERPIGNAN - PARIS LYON
34	POITIERS - PARIS MONTPARNASSE
35	QUIMPER - PARIS MONTPARNASSE
36	RENNES - PARIS MONTPARNASSE
37	ST MALO - PARIS MONTPARNASSE
38	STRASBOURG - NANTES
39	TOULON - PARIS LYON
40	TOULOUSE MATABIAU - PARIS MONTPARNASSE
41	VALENCE ALIXAN TGV - PARIS LYON
42	VANNES - PARIS MONTPARNASSE

	Groupe 3: Trafic
1	ANNECY - PARIS LYON
2	ARRAS - PARIS NORD
3	CHAMBERY CHALLES LES EAUX - PARIS LYON
4	DOUAI - PARIS NORD
5	FRANCFORT - PARIS EST
6	GRENOBLE - PARIS LYON
7	ITALIE - PARIS LYON
8	MACON LOCHE - PARIS LYON
9	MADRID - MARSEILLE ST CHARLES
10	MARSEILLE ST CHARLES - MADRID
11	METZ - PARIS EST
12	PARIS EST - FRANCFORT
13	PARIS VAUGIRARD - NANTES
14	RENNES - PARIS VAUGIRARD
15	STRASBOURG - PARIS EST
16	STUTTGART - PARIS EST
17	TOURCOING - MARSEILLE ST CHARLES
18	TOURS - PARIS MONTPARNASSE
19	ZURICH - PARIS LYON

	Groupe 4: Gestion et voyageurs
1	BORDEAUX ST JEAN - TOURCOING
2	LE CREUSOT MONTCEAU MONTCHANIN - PARIS LYON
3	LILLE - LYON PART DIEU
4	LILLE - MARSEILLE ST CHARLES
5	LILLE - PARIS NORD
6	LYON PART DIEU - LILLE
7	LYON PART DIEU - MARNE LA VALLEE
8	LYON PART DIEU - MARSEILLE ST CHARLES
9	LYON PART DIEU - MONTPELLIER
10	LYON PART DIEU - PARIS LYON
11	MARNE LA VALLEE - LYON PART DIEU
12	MARNE LA VALLEE - MARSEILLE ST CHARLES
13	MARSEILLE ST CHARLES - LILLE
14	MARSEILLE ST CHARLES - LYON PART DIEU
15	MARSEILLE ST CHARLES - MARNE LA VALLEE
16	MARSEILLE ST CHARLES - TOURCOING
17	MONTPELLIER - LYON PART DIEU
18	NANCY - PARIS EST
19	NANTES - STRASBOURG
20	PARIS EST - METZ
21	PARIS EST - REIMS
22	PARIS EST - STUTTGART
23	PARIS LYON - LYON PART DIEU
24	PARIS LYON - SAINT ETIENNE CHATEAUCREUX
25	PARIS LYON - TOULON
26	PARIS LYON - ZURICH
27	PARIS MONTPARNASSE - ANGERS SAINT LAUD
28	PARIS MONTPARNASSE - ANGOULEME
29	PARIS MONTPARNASSE - BORDEAUX ST JEAN
30	PARIS MONTPARNASSE - LA ROCHELLE VILLE
31	PARIS MONTPARNASSE - LAVAL
32	PARIS MONTPARNASSE - LE MANS
33	PARIS MONTPARNASSE - POITIERS
34	PARIS MONTPARNASSE - RENNES
35	PARIS MONTPARNASSE - ST PIERRE DES CORPS
36	PARIS MONTPARNASSE - TOURS
37	PARIS MONTPARNASSE - VANNES
38	PARIS NORD - ARRAS
39	PARIS NORD - DOUAI
40	PARIS NORD - LILLE
41	REIMS - PARIS EST
42	RENNES - LYON PART DIEU
43	SAINT ETIENNE CHATEAUCREUX - PARIS LYON
44	ST PIERRE DES CORPS - PARIS MONTPARNASSE